# INFERENCIA EN REDES BAYESIANAS


*Ana Rosa Aparicio Ramos*

*David Posada Mena*

*3º Ingeniería Informática Ingeniería del Software ETSII*

# Índice

# 1- Descripción del ejemplo elegido

Para afrontar la realización de este trabajo hemos decidido utilizar un supuesto basado en el *lore* de Resident Evil. El bioterrorismo, una amenaza existente en el mundo real, es el pilar sobre el que se desarrolla este mundo. Un virus mutágeno es liberado por accidente (o no) provocando una epidemia global y como producto de ella, el apocalipsis.

Sin entrar en detalles sobre este universo, la consecuencia es que, como en cualquier supuesto post apocalíptico, hay supervivientes que se enfrentan a continuas amenazas entre las que se encuentran, en este caso, los propios mutantes los cuales pierden la condición de humano convirtiéndose en depredadores, la falta de suministros, peligros diversos del entorno y, como no, el propio ser humano.

El objetivo de nuestra red es, basándonos en unas probabilidades lo más cercanas a la realidad posibles, surtir de información sobre la posibilidad de sobrevivir dadas ciertas circunstancias.

A pesar de que dicho mundo es ficticio, nuestra justificación a las probabilidades otorgadas es el sentido común y el pragmatismo ya que el único elemento irreal es la existencia del propio virus. El resto de amenazas (incluyendo la existencia de depredadores con unas características muy concretas) son emulables con cierto grado de realismo. Por ello podemos afirmar que nuestra red es, dentro de la ficción, fidedigna.

A continuación, la representación de dicha red con sus probabilidades.

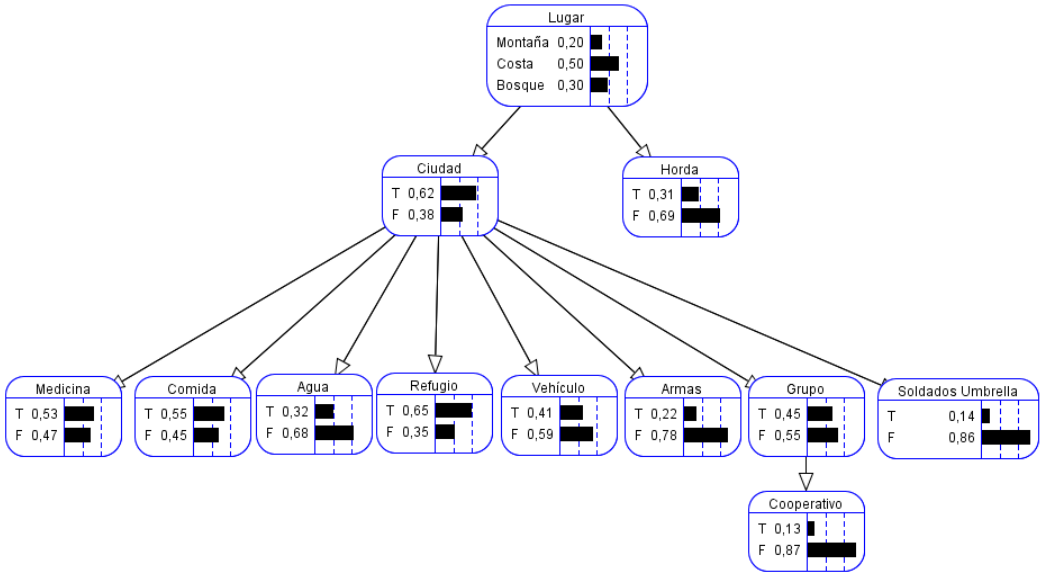

# 2- Descripción de la representación escogida para manejar la red y sus tablas

Las herramientas elegidas para la representación de la red y sus tablas son las siguientes.
Para la representación (el gráfico del punto uno, descripción) hemos utilizado *Believe and Decission Network Tool* (versión 5.1.10). Dicha herramienta es un ejecutable *Java* sencillo de usar que permite la construcción de redes bayesianas y la realización de consultas sobre la misma obteniendo las correspondientes tablas asociadas y permitiendo configurar la consulta de modo que vemos el desarrollo paso a paso de la misma y el funcionamiento del algoritmo.

Por otro lado, para su implementación y utilización mediante nuestro propio código en python hemos utilizado las herramientas empleadas en las clases prácticas. El editor *Jupyter Notebook*, que es un entorno de desarrollo secuencial lanzado mediante el navegador de internet. Permite la edición de archivos tanto locales como alojados en un servidor e importando el paquete *PGMPY*, que permite trabajar con redes bayesianas.

Para facilitar la elaboración del código hemos añadido una extensión de autocompletado a nuestro interprete Jupyter que muestra las funciones y acciones disponibles para los tipos de datos declarados (variables, constantes etcétera).

# 3- Descripción informal del diseño del algoritmo de eliminación de variables, las heurísticas y el recomendador

## *3.1 Algoritmo de eliminación de variables (VE)*

Para diseñar el algoritmo de eliminación de variables se han seguido los siguientes pasos:

**1-Función "descarta":** se encarga de descartar las variables irrelevantes. Recibe como parámetros un modelo de red, una lista de consultas y una lista de evidencias. Y devuelve una lista con las variables irrelevantes.

```
#Paso 1: Función que descarta las variables irrelevantes.

def descarta(m, c, e):
    lista = c+e
    descartados = []
    padres = []
    for l in lista:
        subgrafo = Modelo_residentevil.subgraph(networkx.ancestors(
Modelo_residentevil, l))
        for s in subgrafo:
            padres.append(s)

    for n in m.nodes():
        if n not in lista and n not in padres:
            descartados.append(n)

    return descartados
```

```
#Probando la función descartada

consulta = []
consulta.append("Refugio")
evidencias = []
evidencias.append("Ciudad")
evidencias.append("Cooperativo")

descarta(Modelo_residentevil,consulta,evidencias)
```

```
['Horda',
 'Medicina',
 'Agua',
 'Comida',
 'Vehiculo',
 'Armas',
 'Soldados umbrella']
```

**2- Función "factores_iniciales":** se encarga de construir los factores iniciales. Recibe como parámetros un modelo, una lista de variables descartadas (utilizando para ello la función anterior), y un diccionario de evidencias (cuya clave es el nombre de la variable y el valor es el valor de esa variable en la evidencia). Y devuelve los factores generados.

```
#Paso 2: Función que devuelve los factores iniciales reducidos según las evidencias.

def factores_iniciales(m,d,e):
    c = 0
    factores = {}
    for n in m.nodes():
        if n not in d:
            factores[n]= m.cpds[c].to_factor()
        c+=1
    for k,v in factores.items():
        for i in v.scope():
            if i in e:
                v = v.reduce([(i, e[i])])

    return factores
```

```
#Llamada a la función factores_iniciales
d = descarta(Modelo_residentevil, consulta, evidencias)
e = {'Ciudad':1, 'Cooperativo':1}
factores = factores_iniciales(Modelo_residentevil,d,e)

for clave, valor in factores.items():
    print(clave)
    print(valor.scope())
    print(valor)
```

```
Lugar
['Lugar']
```

| Lugar | phi(Lugar) |
|---|---|
| Lugar_0 | 0.3000 |
| Lugar_1 | 0.2000 |
| Lugar_2 | 0.5000 |

```
Ciudad
['Lugar']
```

| Lugar | phi(Lugar) |
|---|---|
| Lugar_0 | 0.4000 |
| Lugar_1 | 0.8000 |
| Lugar_2 | 0.2000 |

```
Refugio
['Refugio']
```

| Refugio | phi(Refugio) |
|---|---|
| Refugio_0 | 0.4000 |
| Refugio_1 | 0.6000 |

```
Grupo
['Grupo']
```

| Grupo | phi(Grupo) |
|---|---|
| Grupo_0 | 0.2000 |
| Grupo_1 | 0.8000 |

```
Cooperativo
['Grupo', 'Refugio']
```

| Grupo | Refugio | phi(Grupo,Refugio) |
|---|---|---|
| Grupo_0 | Refugio_0 | 0.2000 |
| Grupo_0 | Refugio_1 | 0.6000 |
| Grupo_1 | Refugio_0 | 1.0000 |
| Grupo_1 | Refugio_1 | 1.0000 |

**3- Función "calcula_elimina":** se encarga de calcular las variables ocultas que hay que eliminar. Recibe un conjunto de factores, una lista de consultas y una lista de evidencias. Y devuelve una lista de las variables a eliminar. Esta función se ha implementado a parte para evitar la redundancia de código, ya que era necesario usarla en varias funciones.

```
#Paso 3: Función que elimina las variables ocultas.
def calcula_elimina(factores, consulta, evidencias):
    elimina = []
    for k,v in factores.items():
        if k not in consultas and k not in evidencias:
            elimina.append(k)
    return elimina

def eliminar_variables(factores, consultas, evidencias):
    elimina = calcula_elimina(factores,consultas,evidencias)
    res = {}

    for e in elimina:
        for k,v in factores.items():
            if e in v.scope() and len(v.scope()) > 1:
                phi_not = pgmf.factor_product(factores[e],v)
                phi_not.marginalize([e])
                factores[k] = phi_not
```

```
    for k,v in factores.items():
        for i in v.scope():
            if i in consultas:
                res[k] = v

    return res
```

**4- Función "eliminar_variables":** se encarga de eliminar las variables del conjunto de factores. Recibe como parámetros un conjunto de factores, una lista de consultas y una lista de evidencias. Hace uso de la función anterior "calcula_elimina" para obtener la lista de las variables que necesita eliminar. Devuelve un conjunto de factores con las variables ya eliminadas.

```
#Paso 4 llamada a la función eliminar_variables

consultas = []
consultas.append("Refugio")
evidencias = []
evidencias.append("Ciudad")
evidencias.append("Cooperativo")

d = descarta(Modelo_residentevil, consultas, evidencias)
e = {'Ciudad':1, 'Cooperativo':1}

factores = factores_iniciales(Modelo_residentevil,d,e)

ev = eliminar_variables(factores,consultas,evidencias)

for k,v in ev.items():
    print(k)
    print(v.scope())
    print(v)
```

```
Refugio
['Refugio']
```

| Refugio | phi(Refugio) |
|---|---|
| Refugio_0 | 0.4000 |
| Refugio_1 | 0.6000 |

```
Cooperativo
['Refugio']
```

| Refugio | phi(Refugio) |
|---|---|
| Refugio_0 | 0.8400 |
| Refugio_1 | 0.9200 |

**5- Función "mn_factores":** se encarga de multiplicar los factores restantes y normalizar el resultado. Recibe un conjunto de factores. Y devuelve un factor ya normalizado.

```
#Paso 5: Función que multiplica y normaliza los factores restantes.

def mn_factores(factores):
    m = []
    for k,v in factores.items():
        if not not v.scope():
            m.append(v)

    phi = pgmf.factor_product(*m)
    phi.normalize()

    return phi
#Llamada a la función mn_factores
end = mn_factores(eliminar_variables(factores,consultas,evidencias)
)
print(end)
```

```
╒═══════════╤═══════════════════╕
│ Refugio   │   phi(Refugio)    │
╞═══════════╪═══════════════════╡
│ Refugio_0 │            0.3784 │
├───────────┼───────────────────┤
│ Refugio_1 │            0.6216 │
╘═══════════╧═══════════════════╛
```

Por último, se ha usado la herramienta **"VariableElimination"** (que ya dispone de la implementación del proceso de eliminación de variables) con el objeto de comprobar el correcto resultado obtenido con las funciones implementadas anteriormente.

```
#Uso de la herramienta VariableElimination para comprobar el correc
to resultado usando el ejemplo 1

Modelo_re_ev = pgmi.VariableElimination(Modelo_residentevil)
consulta = Modelo_re_ev.query(['Refugio'], {'Ciudad': 1, 'Cooperati
vo': 1})
print(consulta['Refugio'])
```

```
╒═══════════╤═══════════════════╕
│ Refugio   │   phi(Refugio)    │
╞═══════════╪═══════════════════╡
│ Refugio_0 │            0.3784 │
├───────────┼───────────────────┤
│ Refugio_1 │            0.6216 │
╘═══════════╧═══════════════════╛
```

## 3.2 Heurísticas

-**Min Degree**: dado un conjunto de factores, la variable que se decide eliminar es la que está conectada con menos variables en el conjunto de factores. Decimos que una variable está conectada con otra respecto de un conjunto de factores, cuando ambas aparecen en un mismo factor del conjunto.

```
def min_degree(factores, consultas, evidencias):
    res = {}
    elimina = calcula_elimina(factores, consultas, evidencias)
    cont = 0
    for e in elimina:
        for k,v in factores.items():
            if e in v.scope() and len(v.scope()) > 1:
                cont=cont+1
        res[e] =cont
        cont = 0
    resultado = sorted(res.items(), key=operator.itemgetter(1))
    return resultado

print("El orden de eliminación usando heurística Min Degree es:",
      min_degree(factores, consultas, evidencias))
```

-**Min Fill**: dado un conjunto de factores, la variable que se decide eliminar es aquella que al eliminarse introduciría menos conexiones nuevas (conexiones en el sentido explicado en el punto anterior).

```
#El coste de eliminar un nodo es el número de aristas que se añaden
al eliminarlo
def min_fill(factores, consultas, evidencias):
    res = {}
    elimina = calcula_elimina(factores, consultas, evidencias)
    cont = 0

    for e in elimina:
        res[e] = len(list(combinations(Modelo_residentevil.neighbor
s(e), 2)))
    resultado = sorted(res.items(), key=operator.itemgetter(1))
    return resultado

print("El orden de eliminación usando heurística Min Fill es:",
      min_fill(factores, consultas, evidencias))
```

## 3.3 Recomendador

Nuestro recomendador utiliza el algoritmo de inferencia aproximada **muestreo por rechazo.** Es una función que recibe como parámetros la red, la consulta y un conjunto de candidatas a ser evidencias. El resultado de la ejecución es la recomendación de una nueva evidencia. Dicha evidencia será la que mayores cambios aporte a la consulta pudiendo cambiar totalmente los resultados y ayudando a decidir al usuario acerca de las decisiones que debe tomar en base a las probabilidades aportadas por la red.
A continuación, se incluye el código de dicho recomendador junto con las funciones que necesita para llevar a cabo su trabajo:

Primeramente, necesitamos generar un valor aleatorio dentro de los valores disponibles en la cardinalidad de cada variable

```
import random

#Función que devuelve una probabilidad concreta del modelo
def seleccionar_probabilidad(cpd, valor, evidencia):
    # Buscamos los padres de una evidencia
    padres = cpd.evidence if cpd.evidence else []
    # Buscamos los valores asociados a los padres
    valores_evidencia = tuple(evidencia[var] for var in padres)
    # Buscamos los valores de la distribución de probabilidad conju
nta
    return cpd.values[valor][valores_evidencia]



#Función que genera un valor aleatorio según la cardinalidad de la
variable
def generar_valor_aleatorio(cardinalidad, probabilidades):
    p = random.random()
    acumuladas = 0
    for valor in range(cardinalidad):
        acumuladas += probabilidades[valor]
        if p <= acumuladas:
            return valor
```

A continuación, necesitamos generar una muestra aleatoria a fin de estudiarla utilizando las funciones definidas en el paso anterior.

```
#Función que genera una muestra aleatoria dada una red bayesiana
#Esta función usa las dos anteriores (seleccionar_probabilidad y ge
nerar_valor_aleatorio)
def muestra_aleatoria(red):
    variables = networkx.topological_sort(red)
    muestra = {}
    for variable in variables:
        tabla = Modelo_residentevil.get_cpds(variable)
        #TODO: con Lugar no funciona bien, hay que arreglarlo
        if variable != 'Lugar':
            cardinalidad = tabla.variable_card
```

```
            probabilidades = [seleccionar_probabilidad(tabla, i, mu
estra)
                              for i in range (cardinalidad)]
            valor = generar_valor_aleatorio(cardinalidad, probabili
dades)
        else:
            valor = 0
        muestra[variable] = valor

    return muestra
```

El siguiente paso es definir la función que mediante el algoritmo de muestreo por rechazo devuelva las frecuencias.

```
import itertools

#Función que devuelve las frecuencias aplicando el algoritmo de mue
streo por rechazo
def muestreo_con_rechazo(red, consulta, evidencia, N):
    muestras = [muestra_aleatoria(red) for i in range(N)] # Me gene
nará una muestra de N valores

    # Ahora nos quedamos con aquellas en las que la muestra y la ev
idencia coinciden
    muestrasValidas = []
    for muestra in muestras:
        if all(muestra[variable] == evidencia[variable]
               for variable in evidencia):
            muestrasValidas.append(muestra)

    cardinalidades = [red.get_cpds(variable).variable_card
                      for variable in consulta]

    # Calculamos las combinaciones
    combinaciones = itertools.product(*(range (i)
                                        for i in cardinalidades))

    # Ahora contamos las combinaciones, es decir, el nº de veces qu
e ocurre cada cosa
    # Recuerda: es un diccionario
    frecuencias = {combinacion : 0
                   for combinacion in combinaciones}

    for muestra in muestrasValidas:
        combinacion = tuple(muestra[variable]
                            for variable in consulta)
        frecuencias[combinacion] += 1

    #print (combinaciones)
    #print (frecuencias)
    #print (len(muestras))
    #print (len(muestrasValidas))
    return frecuencias
```

Por último, definimos nuestro recomendador, que utilizando las funciones definidas anteriormente y basándose en el algoritmo de muestreo por rechazo nos recomendará el nodo que aporte un cambio más significativo al ser añadido como evidencia a las ya existentes.

```
def recomendador(modelo, consulta, evidencias):
    k = 0
    suma = 0
    i = 0
    candidatas = []
    e = list(evidencias.keys())
    nevidencias = {}
    res={}

    descartes = descarta(modelo, consulta, e)
    nodos = modelo.nodes()

    #Calculamos las candidatas
    for n in nodos:
        if (n not in consulta) and (n not in e) and (n not in desca
rtes):
            candidatas.append(n)

    #Aplicamos muestreo por rechazo con las candidatas con valor 0
    for c in candidatas:
        nevidencias.update(evidencias)
   #Añadimos al diccionario de evidencias la candidata con valor 0
        nevidencias[c] = 0
        #Llamamos al algoritmo muestreo con rechazo
        frecuencias = muestreo_con_rechazo(modelo, consulta, nevide
ncias, 10000)
        #Normalizamos
        suma = frecuencias[(0,)] + frecuencias[(1,)]
        pno = frecuencias[(0,)] / suma
        psi = frecuencias[(1,)] / suma
        #Calculamos la diferencia
        dif = abs(pno-psi)
        #Asignamos la nueva candidata si la diferencia es mayor
        if(k < dif):
            k = dif
            i = 0
            r = c
        nevidencias.clear()

    #TODO: esto hay que arreglarlo, ya que Lugar no lo coge bien, t
engo que borrarla
    candidatas.remove('Lugar')

    #Aplicamos muestreo por rechazo con las candidatas con valor 1
    for c in candidatas:
        nevidencias.update(evidencias)
   #Añadimos al diccionario de evidencias la candidata con valor 1
        nevidencias[c] = 1
        #Llamamos al algoritmo muestreo con rechazo
        frecuencias = muestreo_con_rechazo(modelo, consulta, nevide
ncias, 10000)
        #Normalizamos
        suma = frecuencias[(0,)] + frecuencias[(1,)]
```

```
        pno = frecuencias[(0,)] / suma
        psi = frecuencias[(1,)] / suma
        #Calculamos la diferencia
        dif = abs(pno-psi)
        #Asignamos la nueva candidata si la diferencia es mayor
        if(k < dif):
            k = dif
            i = 1
            r = c
        nevidencias.clear()

  #Devolvemos la var candidata cuya dif es mayor como recomendación
    res[r] = i
    return res
```

# 4- Sección de experimentación con ejemplos concretos del uso del algoritmo y del recomendador

La consulta utilizada como ejemplo durante el desarrollo del algoritmo ha sido: la probabilidad de que **Refugio** sea **verdadero**, sabiendo que **Ciudad** y **Cooperativo** son **verdaderos**.

```
#Probando la función muestra aleatoria
muestra_aleatoria(Modelo_residentevil)
```

```
{'Agua': 0,
 'Armas': 0,
 'Ciudad': 0,
 'Comida': 0,
 'Cooperativo': 0,
 'Grupo': 0,
 'Horda': 0,
 'Lugar': 0,
 'Medicina': 1,
 'Refugio': 0,
 'Soldados umbrella': 1,
 'Vehiculo': 0}
```

```
#Probando la función muestreo por rechazo, que devuelve las frecuencias
random.seed(12345)
print('Las frecuencias son:',muestreo_con_rechazo(Modelo_residentevil, ['Refugio'], {'Ciudad': 1, 'Cooperativo': 1}, 10000))
```

```
Las frecuencias son: {(0,): 818, (1,): 2340}
```

A fin de probar el recomendador se realizan las siguientes consultas dando los correspondientes resultados:

```
#Probando la función recomendador
vr = recomendador(Modelo_residentevil, ['Refugio'], {'Ciudad': 1, 'Cooperativo': 1})
```

```
print('La variable recomendada es:',vr)
```

```
La variable recomendada es: {'Grupo': 0}
```

Segundo ejemplo del recomendador

```
#Probando el recomendador con el ejemplo 2
vr = recomendador(Modelo_residentevil, ['Ciudad'], {'Agua': 1, 'Refugio': 0})
print('La variable recomendada es:',vr)
```

```
La variable recomendada es: {'Lugar': 0}
```

Ahora realizamos otro ejemplo sobre la utilización del algoritmo de eliminación de variables

```
# Construyendo el ejemplo 2
consultas.append("Ciudad")
evidencias = []
evidencias.append("Agua")
evidencias.append("Refugio")

d = descarta(Modelo_residentevil, consultas, evidencias)
e = {'Agua':1, 'Refugio':0}

factores = factores_iniciales(Modelo_residentevil,d,e)

ev = eliminar_variables(factores,consultas,evidencias)
end = mn_factores(eliminar_variables(factores,consultas,evidencias))
print(end)
```

```
╒═══════════╤═══════════════════╕
│ Ciudad    │   phi(Ciudad)     │
╞═══════════╪═══════════════════╡
│ Ciudad_0  │            0.7099 │
├───────────┼───────────────────┤
│ Ciudad_1  │            0.2901 │
╘═══════════╧═══════════════════╛
```

```
#Uso de la herramienta VariableElimination para comprobar el correcto resultado usando el ejemplo 2
Modelo_re_ev = pgmi.VariableElimination(Modelo_residentevil)
consulta = Modelo_re_ev.query(['Ciudad'], {'Agua': 1, 'Refugio': 0})
print(consulta['Ciudad'])
```

```
╒═══════════╤═══════════════════╕
│ Ciudad    │   phi(Ciudad)     │
╞═══════════╪═══════════════════╡
│ Ciudad_0  │            0.7099 │
├───────────┼───────────────────┤
│ Ciudad_1  │            0.2901 │
╘═══════════╧═══════════════════╛
```

# 5- Bibliografía

http://pgmpy.org/
https://stackoverflow.com/
http://aispace.org/bayes/
http://www.cs.waikato.ac.nz/ml/weka/